V4-SCOPE-RL

基于硬安全动作掩码的候选轨迹强化学习

论文研究附录与终局阴性结果

项目论文技术稿

从冻结合同、训练回执与 fresh-seed 证据自动导出

2026 年 8 月 7 日

范围声明

本附录在冻结 V3-SCOPE 证据之后建立独立的 V4-SCOPE-RL。V4 没有改写 V2/V3 结果， 没有连接稳定实车工作区，没有发布实车命令，也没有进行在线 TEB 参数写入。研究只使用 确定性快速交互仿真；由于预注册学习门失败，Gazebo、Actual TEB 正式比较和实车阶段均未启动。

本研究的完整结论是：**强化学习模块与硬安全动作掩码已经实现并通过组件测试，但没有 证明其相对同候选集解析排序器具有有意义的效率提升。** 该阴性结果不是“无结果”；它给出了 动作支持、训练预算、选模规则和学习价值边界，为论文中“何时不应启用强化学习”提供可复核证据。

摘要

V3-SCOPE 使用解析函数在经过 Ackermann 可行性与硬安全验证的候选中进行一次性选择。为研究 动态 actor 响应下的序列决策价值，本附录提出 V4-SCOPE-RL：以 0.25 s 周期重复构建候选， 硬验证器产生布尔安全动作掩码，Masked-PPO 只能在掩码允许的候选 ID 上采样和更新。学习器无权 改变候选几何、运动学、占据预测、安全阈值、certified-stop 回退和 `/cmd_vel_navigation` 命令边界。

全局预算冻结为三轮单因素、600,000 个训练环境步和 240 个未使用的 Gazebo 单元。初始探针、 响应持续时间因素、时间奖励对齐因素和最终 actor 响应率因素均被完整保存。两个训练种子的最佳 验证改善仅为 0.104% 和 0.073%，低于 3% 学习门。终局 30 个 fresh paired blocks 中， 解析/Masked-PPO 均为 30/30 成功、0 接触、0 掩码违规，受限时间为 7.7750/7.7667 s；配对相对 降幅仅 0.0980%，双侧 95% block-bootstrap 区间为 [0, 0.2941%]，仅 1/30 块为正。 因此不支持显著或有意义的学习优化声明，但支持“模块实现、掩码完整性和失败关闭”的工程结论。

关键词： 安全强化学习；无效动作掩码；PPO；Ackermann 轨迹；反应式 actor； 预注册阴性结果

Contents

范围声明 I

摘要 II

1 研究动机与问题定义 1
- 1.1 从 V3 解析排序到 V4 序列决策 . . . 1
- 1.2 预注册假设与停止规则 . . . 1

2 V4-SCOPE-RL 架构 2
- 2.1 学习权限与安全权限分离 . . . 2
- 2.2 状态、奖励与 Masked-PPO . . . 2

3 实验合同与实现验证 4
- 3.1 预算和身份隔离 . . . 4
- 3.2 学习价值与组件门 . . . 4

4 结果 5
- 4.1 训练与验证结果 . . . 5
- 4.2 Fresh-seed 终局刻画 . . . 5

5 讨论与论文结论 8
- 5.1 为什么强化学习没有产生有意义的增益 . . . 8
- 5.2 可以写入论文的贡献 . . . 8
- 5.3 不能写入论文的声明 . . . 8
- 5.4 后续研究建议 . . . 9

6 复现资源索引 10

List of Tables

3.1 V4 单因素阶段与冻结判定 4

4.1 V4-04-N1 fresh-seed 快速仿真结果 6

List of Figures

2.1 V4-SCOPE-RL 数据流。绿色模块是唯一学习权限；红色模块保持为硬安全边界。 2

4.1 三轮单因素与终局刻画的配对时间降幅。虚线为冻结的 3% 门。 5
4.2 每个 fresh block 的解析时间减 Masked-PPO 时间。29/30 为零。 6
4.3 30 个 fresh blocks 中两种方法的动作计数。学习策略整体复现解析决策。 7

Chapter 1

研究动机与问题定义

1.1　从 V3 解析排序到 V4 序列决策

V3 的正式 Gazebo 比较在共同门状态生成一次候选集合，选择一条空间轨迹并跟踪到目标。V3-04 学习审计发现：308/308 次决策都有解析候选可用，183 次决策有多个安全候选，但解析选择的立即 进度后悔为零；同时，日志对未执行动作的 propensity 为零，不支持离线序列强化学习。这说明 直接把一个神经网络叠加在 V3 日志上既无识别基础，也不能形成可信论文贡献。

V4 改变的是决策过程而不是安全边界：在反应式 actor 会受早期自车动作影响的环境中， 每 0.25 s 重新决策。研究问题冻结为：在任务成功和硬安全门不退化的前提下，Masked-PPO 是否 能将 failure-inclusive restricted time 相对解析排序器至少降低 3%？相对 Actual TEB 的结果 只能作为次要问题，且不能替代与解析排序器的直接比较。

1.2　预注册假设与停止规则

阳性判定必须同时满足：目标成功率不劣于解析基线、接触为零、掩码违规为零、激活复核失败为零、 配对时间点估计至少 3%，并且独立训练种子方向一致。每轮只允许改变一个因素；淘汰预算不可回收， 不允许使用测试结果选检查点、替换不利种子或删除 timeout。三轮结束后，无论结果如何均停止训练。

Chapter 2

V4-SCOPE-RL 架构

2.1 学习权限与安全权限分离

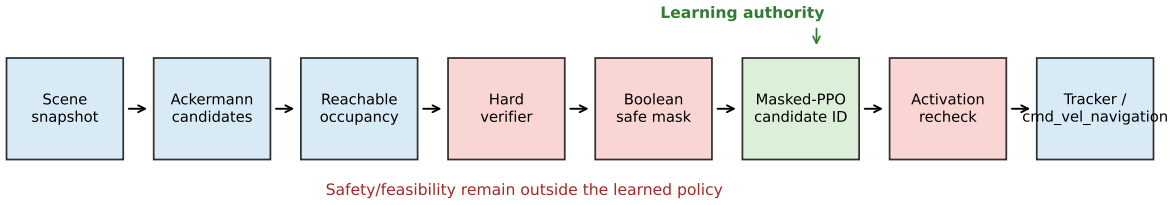


Figure 2.1: V4-SCOPE-RL 数据流。绿色模块是唯一学习权限；红色模块保持为硬安全边界。

如图 2.1，策略输出是离散候选 ID，不是速度、转角或 TEB 参数。固定动作支持包含 certified stop、0.4/0.8/1.2 m/s 直行候选以及左右空间候选。所有候选先由 Ackermann 运动学生成， 再与 actor 可达占据进行保守距离检查。停止候选始终存在；掩码为空被视为程序错误并失败关闭。

对于策略网络输出的 logits $z_\theta(s,a)$ 和硬验证掩码 $m(s,a) \in \{0,1\}$，实际分布使用

$$\tilde{z}_\theta(s,a) = \begin{cases} z_\theta(s,a), & m(s,a) = 1, \\ -\infty, & m(s,a) = 0, \end{cases} \qquad \pi_\theta(a \mid s, m) = \mathrm{softmax}(\tilde{z}_\theta). \tag{2.1}$$

因此被拒绝动作的采样概率和对应 logit 梯度均为零。该设计与无效动作掩码的策略梯度分析一致 [2]，在系统角色上接近 pre-shielding：安全层先给出允许动作集合，再由学习器 选择[3]。不过，本项目仅验证实现与经验门，不声称形式化安全。

2.2 状态、奖励与 Masked-PPO

状态由 12 个全局特征和 6×5 个候选特征组成：自车进度、横向位置、航向、速度、前一动作， actor 坐标、速度与加速度估计、到达时间差，以及每个候选的接受位、

投影进度、保守净空、加速度 代价和横向偏移。网络为两层 128 单元 Tanh actor–critic。PPO 使用裁剪代理目标

$$L^{\text{clip}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t \right) \right], \tag{2.2}$$

其中概率比 r_t 在同一个硬掩码分布上计算[1]。安全不是可交换的碰撞惩罚； 奖励只在安全集合内优化进度、耗时、速度变化、动作切换、目标和 timeout。

Chapter 3

实验合同与实现验证

3.1 预算和身份隔离

表 3.1 列出完整闭合链。R0 使用 100,000 步；F1 为 150,000 步；F2 的两个种子各 150,000 步；F3 使用最后 50,000 步，总计恰好 600,000 步。每个阶段使用不同的审计、验证或 终局 fresh seed 区间。测试种子不参与任何拟合和选模。

Table 3.1: V4 单因素阶段与冻结判定

阶段	唯一变化/目的	训练步	最佳改善	结论
V4-02-R0	基线开发探针	100,000	0.000%	失败
V4-03-F1	actor 让行响应持续时间	150,000	0.000%	失败
V4-03-F2/4103	耗时奖励与主指标对齐	150,000	0.104%	失败
V4-03-F2/4104	独立训练种子复核	150,000	0.073%	失败
V4-03-F3	actor 纵向响应率	50,000	0.000%	失败
V4-04-N1	30 个 fresh 终局刻画	0	0.098%	阴性闭合

3.2 学习价值与组件门

F1 在训练前执行 100 个新状态块、600 个候选反事实回合。安全多动作状态比例为 100%，17% 的 块存在正序列后悔，超过 5% 启动门；但平均后悔仅 0.6165%，已经提示可学习效应很小。F3 在训练 前又运行 1000 个均匀随机安全掩码回合，得到 0 接触、0 掩码违规和最小经验净空 0.3172 m。 最终 Python 测试共 9 项，覆盖合同、停止候选、拒绝动作不投影、克隆重放、掩码概率、短训练和 检查点往返，9/9 通过。

Chapter 4

结果

4.1 训练与验证结果

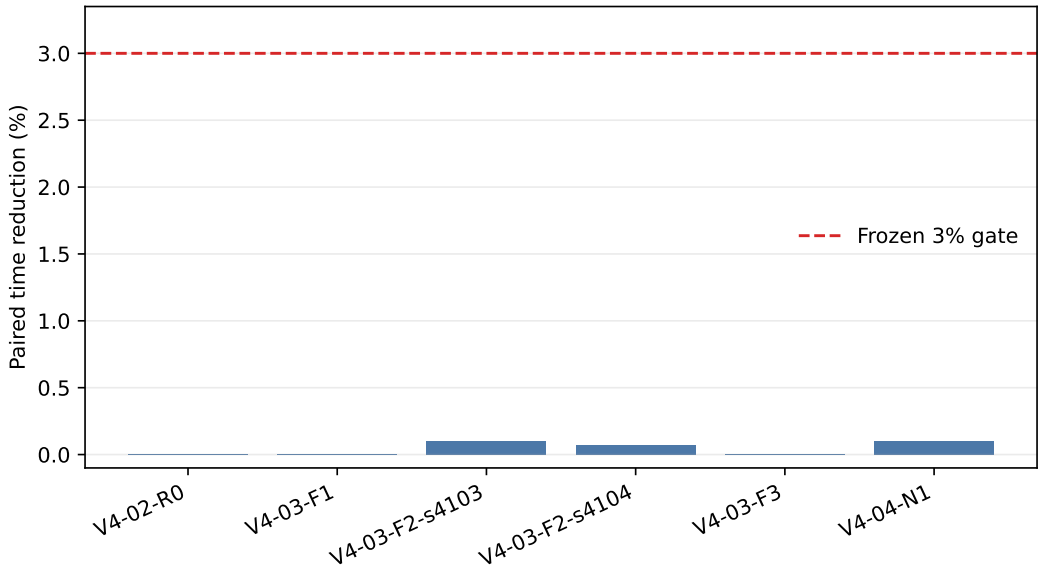


Figure 4.1: 三轮单因素与终局刻画的配对时间降幅。虚线为冻结的 3% 门。

图 4.1 显示 F1 的策略与解析排序器完全相同。F2 提高耗时权重后，两个训练种子都出现 正方向，但只有 0.104% 和 0.073%；跨种子均值 0.0883%。F3 的响应率因素通过随机安全预检， 但策略再次收敛到解析选择。三轮均未接近 3% 门，继续增加预算没有预注册依据。

4.2 Fresh-seed 终局刻画

冻结 F2 中验证回报最高的 seed4104 检查点后，V4-04-N1 使用 seeds 430100–430129 运行 30 个 新配对块。表 4.1 汇总结果。

配对相对降幅为 0.0980%，双侧 95% paired-block percentile bootstrap 区间为 $[0, 0.2941\%]$。只有一个块缩短 0.25 s，其余 29 个块完全相同（图 4.2）。因此区间 没

Table 4.1: V4-04-N1 fresh-seed 快速仿真结果

方法	成功	受限均时/s	接触	掩码违规
同候选集递推解析排序	30/30	7.7750	0	0
Masked-PPO seed4104	30/30	7.7667	0	0

有显示负方向并不等于存在实质收益：点估计只有冻结最小效应 3% 的约 1/31。

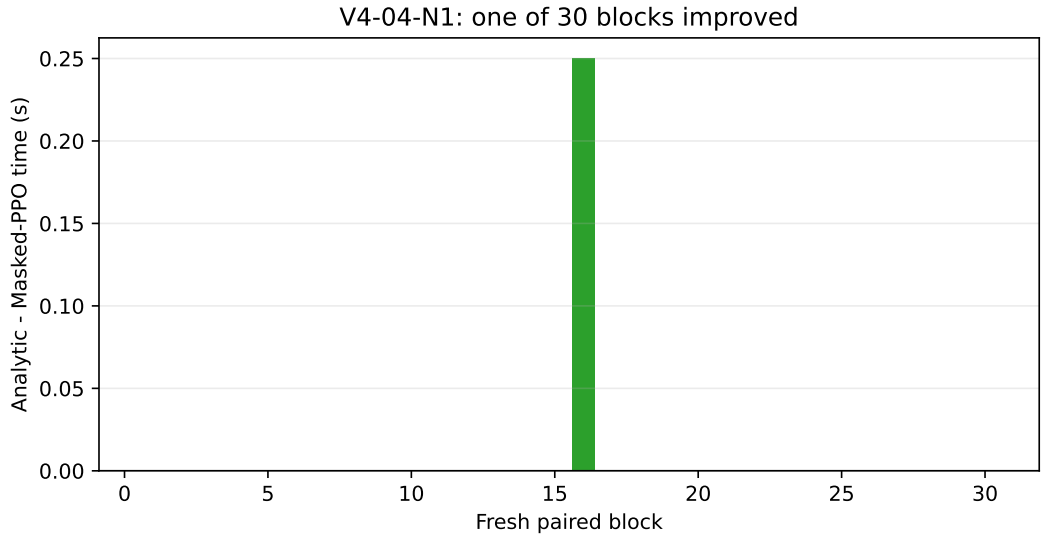


Figure 4.2: 每个 fresh block 的解析时间减 Masked-PPO 时间。29/30 为零。

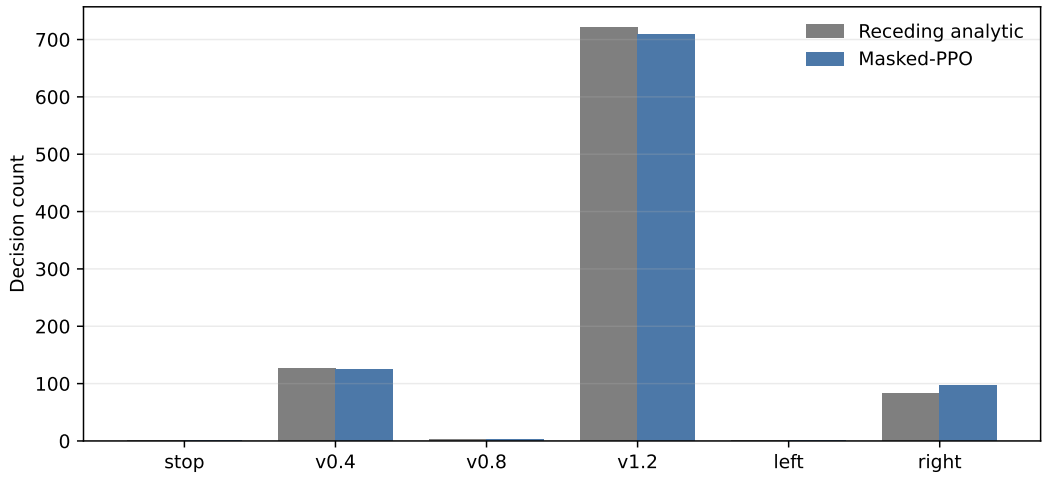


Figure 4.3: 30 个 fresh blocks 中两种方法的动作计数。学习策略整体复现解析决策。

Chapter 5

讨论与论文结论

5.1 为什么强化学习没有产生有意义的增益

结果并非 PPO 数值发散：所有种子安全和任务门稳定，回报收敛且检查点可重放。主要限制是 **安全候选集合中的长程后悔太小**。解析排序器已经在每个 0.25 s 周期重算安全集并优先选择 投影进度最大的动作；绝大多数块中，长期最优动作与立即解析动作一致。F1 的反事实审计虽然通过 “存在性”门，但平均可利用后悔只有 0.62%。这不足以支撑 3% 的论文效应，更不应通过增加网络 规模、替换种子或放宽门槛来制造阳性。

5.2 可以写入论文的贡献

第一，V4 提供了一个真实可运行的 RL 模块，而不是把 V3 解析器改名为学习器：包含 Gymnasium 序列环境、Masked-PPO actor–critic、GAE、裁剪更新、多环境 rollout、检查点和确定性评测。 第二，学习权限与安全权限严格分离；1000 个随机掩码预检和 30 个 fresh 配对块均为 0 接触、0 掩码违规。第三，预注册三轮因素给出了重要阴性认识：在安全候选已经由强解析器近似饱和时， “加入 RL”本身不是性能贡献。第四，所有不利结果、超参数、种子和停止条件被保留，可作为论文的 消融、局限性和研究诚信材料。

5.3 不能写入论文的声明

本研究没有 V4 Gazebo 结果，不能声称 V4 优于 Actual TEB；没有多人、感知、OOD 或真实硬件结果； 经验上的 0 接触不是形式化安全证明；0.098% 点改善也不是显著或有意义的强化学习收益。 历史 V3-11 的 scoped Gazebo 阳性和 V3-21 的失效计入式阴性仍应分别报告，不能与 V4 快速仿真 合并成一个更有利的总体效应。

5.4 后续研究建议

若未来重新开启新研究，不应继续当前超参数搜索。合理入口是先引入具有可识别长程后悔的新任务 族，例如多 actor 次序协商、遮挡下的信息收集动作或明确的机会成本，再以独立几何和 fresh seed 重新做学习价值审计。只有同候选集解析控制上存在足够的序列 regret，强化学习比较才有统计功效。 任何 Gazebo 或实车阶段都需要新的合同、预算和授权。

Chapter 6

复现资源索引

机器可读资源位于 artifacts/v4/paper/v4_06_p1_thesis_export/：

- v4_04_n1_method_summary.csv：方法级主表；
- v4_04_n1_paired_blocks.csv：30 个配对块；
- v4_factor_history.csv：全部训练因素与预算；
- v4_06_p1_claims.yaml：允许与禁止声明；
- 三幅 SVG/PDF 结果图和一幅架构图；
- v4_06_p1_evidence_manifest.sha256：路径–SHA256 证据清单。

核心实现位于 src/application/v4_scope_rl/。组件测试 XML 为 artifacts/v4/v4_component_tests.xml。历史 V3 论文 PDF 保持原 SHA，不被覆盖；最终合并稿只在 其后追加本附录。

Bibliography

[1] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal Policy Optimization Algorithms," arXiv:1707.06347, 2017. https://arxiv.org/abs/1707.06347

[2] S. Huang and S. Ontañón, "A Closer Look at Invalid Action Masking in Policy Gradient Algorithms," arXiv:2006.14171, 2020. https://arxiv.org/abs/2006.14171

[3] M. Alshiekh et al., "Safe Reinforcement Learning via Shielding," Proceedings of the AAAI Conference on Artificial Intelligence, 2018. https://ojs.aaai.org/index.php/AAAI/article/view/11797