PCT-SCOPE-RL

利用仿真特权信息训练、以真实传感器端到端评估候选轨迹，并由硬安全屏蔽和解析先验共同约束的 Ackermann 局部导航强化学习架构

论文方法、正式结果与迁移边界附录

项目论文技术稿

由冻结合同、训练回执、fresh-seed 正式评估与失败预检证据导出

2026 年 8 月 8 日

范围声明

本文给出一个已经实现并训练的强化学习模块，而不是把解析排序器重新命名为 RL。部署 actor 只读取六帧激光、里程计、局部目标、候选描述、解析先验和硬掩码；仿真世界状态只进入训练期 critic 与反事实候选排序目标，actor-only 检查点不包含特权模块。动作是 8 个经过 Ackermann 运动学生成的候选轨迹 ID，而不是无约束速度、转角或 TEB 参数。

在 80 个全新配对块的冻结快速交互总体上，PCT-SCOPE-RL 相对同候选集解析先验将失效计入的 受限均时降低 8.4024%，双侧 97.5% paired-block bootstrap 区间为 [3.4840%, 13.7135%]，目标数 60/80 对 49/80，接触与掩码违规均为零，全部预注册门通过。 这是本文的主阳性结果。

同时必须保留反证边界：三次单块 Gazebo 预检均未通过冻结的保守净空门，因此没有启动 Gazebo 资格或正式矩阵，也没有得到相对 Actual TEB 的学习优势。本文不声称形式化安全、通用感知、 多 actor/OOD 泛化、部署或实车有效性。历史消融还显示 V6 与 no-history 版本结果完全相同， 故不声称 GRU 历史记忆产生收益。

摘要

传统端到端导航强化学习可直接从激光映射到速度，但连续控制输出难以同时保持 Ackermann 可行性、 安全可审计性和已有解析规划知识。本文提出 PCT-SCOPE-RL：首先由确定性运动学生成器构建 certified stop、三条直行和四条空间候选；传感器 actor 以 CNN–GRU 编码激光历史，并对每个候选 输出相对解析先验的残差分数；硬安全屏蔽在采样和执行前拒绝不可接受候选；优势门仅在学习残差 相对解析动作超过冻结阈值时允许覆盖。训练阶段采用 asymmetric PPO，critic 可读仿真特权状态； 进一步提出 privileged counterfactual trajectory-rank distillation（PCT），用世界状态构造困难 交互中的反事实候选排序标签，并以辅助交叉熵监督同一个传感器 actor。部署时删除 critic 和标签。

V5 首次实现完整传感器 actor，在 60 个 fresh blocks 上仅得到 6.0936% 降幅，未达到 8% 门。 V6 只增加 PCT 单因素，使用 4 个训练身份各 120,000 新环境步；验证门四个身份方向全正。随后 80 块正式评估得到 8.4024% 主效应与正区间，且相对冻结 V5 的次要改善为 3.1611%。分场景 结果显示增益集中在部分遮挡 crossing；窄走廊四方法均失败，说明阳性并非一般导航解决方案。 Gazebo 预检进一步暴露当前扫描屏蔽与反应式 actor 闭环的迁移缺口，为论文提供可复核的外部 效度边界。

关键词： 强化学习；仿真特权信息；Asymmetric PPO；知识蒸馏；候选轨迹； Ackermann 运动学；硬安全屏蔽；端到端传感器策略

Contents

范围声明 I

摘要 II

1 研究问题与创新定位 1

1.1 问题定义 1

1.2 创新点及其边界 1

2 PCT-SCOPE-RL 架构 2

2.1 总体数据流 2

2.2 观测、候选与 actor 2

2.3 Asymmetric PPO 与 PCT 3

2.4 硬安全屏蔽 3

3 实验设计与实现 4

3.1 阶段链与预算 4

3.2 训练过程与组件审计 4

4 正式结果 6

4.1 主效应与任务结果 6

4.2 场景分解与消融 7

5 Gazebo 迁移负结果 8

5.1 三次预检 8

5.2 对论文结论的影响 9

6 讨论、贡献与局限 10

6.1 为什么该工作属于强化学习 10

6.2 为什么该工作是端到端而非端到端控制 10

6.3 论文可支持的贡献 10

6.4 禁止扩大的声明 11

7 复现资源索引 **12**

List of Tables

3.1 V5–V6 关键阶段与冻结结论 4

4.1 V6-02-F1 方法级结果 6

5.1 Gazebo 预检终局结果（每方法 1 个新鲜 episode） 8

List of Figures

2.1 PCT-SCOPE-RL 训练与部署数据流。紫色特权路径在 actor-only 部署检查点中被删除。 2

3.1 四个 V6 训练身份的 PCT 排序准确率与 rollout reward。 5

4.1 80 个 fresh blocks 的方法均时与目标成功数。 6
4.2 V5/V6 效应点估计与冻结 bootstrap 区间。 7
4.3 四类交互场景的失效计入均时。 7

5.1 三次 Gazebo 预检的最小保守净空；零线为冻结完整性门。 8

Chapter 1

研究问题与创新定位

1.1 问题定义

机器人在时刻 t 获得传感器观测 $o_t = (L_{t-5:t},\, x_t^{\text{odom}},\, g_t)$，其中 L 为 72 束激光，g_t 为局部目标。 运动学生成器给出有限候选集 $\mathcal{T}_t = \{\tau_t^1, \ldots, \tau_t^8\}$。研究目标不是学习 任意控制量，而是在硬可行集合 $\mathcal{A}_{\text{safe}}(o_t) \subseteq \{1, \ldots, 8\}$ 中学习 候选选择策略，并保持解析排序器作为可解释先验与回退。

仿真训练还可获得特权变量 p_t，包括 actor 真实位置、速度、模式、危险侧和完整交互状态。 部署策略必须满足

$$a_t \sim \pi_\theta(a \mid o_t, \mathcal{T}_t, m_t), \qquad \frac{\partial a_t}{\partial p_t} = 0, \tag{1.1}$$

其中 m_t 为硬安全掩码。特权信息可以影响参数学习，但不能出现在部署图中。

1.2 创新点及其边界

PPO、asymmetric actor–critic、privileged teacher、安全 shielding 和候选轨迹规划分别已有研究 基础[1, 2, 3, 4, 6]。 本文不把这些单独机制宣称为首创。可写入论文的组合创新是：

1. 将 RL 动作空间从高维 TEB/连续控制参数改为**预生成 Ackermann 可执行候选 ID**， 使学习权限、运动学权限与命令权限可分离审计；
2. 提出**解析先验上的优势门控残差 actor**：神经策略不必重学基本进度/净空规律，仅在学到足够反事实优势时覆盖解析动作；
3. 提出**PCT 训练目标**：仿真特权信息不进入部署 actor，而只产生困难场景候选排序标签， 与 privileged critic 同时训练同一传感器策略；
4. 将硬掩码置于候选采样和执行边界，保留 certified-stop，形成“学习优化性能、解析提供先验、 verifier 掌握否决权”的三权分离架构；
5. 用 V5 阴性、V6 单因素阳性和 Gazebo 迁移阴性组成完整证据链，不用不利结果调参或删样本。

Chapter 2

PCT-SCOPE-RL 架构

2.1 总体数据流

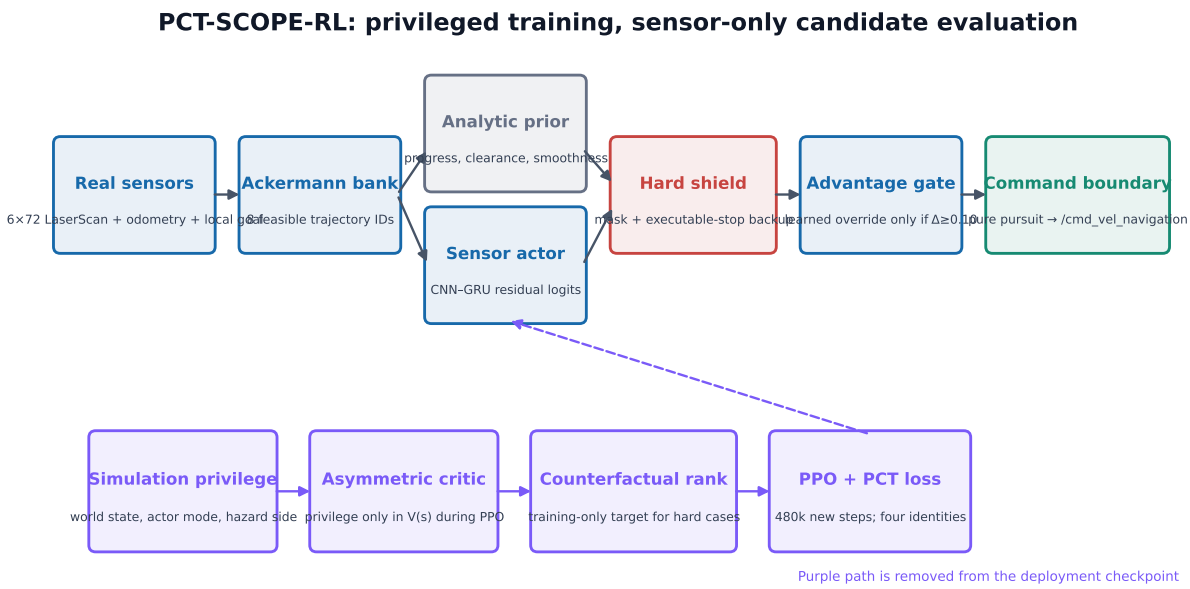


Figure 2.1: PCT-SCOPE-RL 训练与部署数据流。紫色特权路径在 actor-only 部署检查点中被删除。

如图 2.1，部署数据流从传感器到候选评分再到 `/cmd_vel_navigation`，中间不读取 Gazebo model states 或 actor 真值轨迹。硬件侧原 GPS 限幅器、FOD 模式仲裁和 M2 驱动边界无需改变。与直接速度策略相比，轨迹候选输出保留了控制器 可跟踪性；与直接调 TEB 参数相比，单次决策不会产生高维、耦合且大量被投影的动作。

2.2 观测、候选与 actor

激光编码器对每帧使用一维卷积，随后以 GRU 融合 6 帧；里程计/目标向量经 MLP 编码。每个候选 包含目标速度、横向偏移、预测进度、净空、加速度代价、横向代价和

切换代价。解析分数

$$q_{\text{ana}}(o,\tau) = \Delta x + 1.5\,\text{clip}(c,-1,2) - 0.035J_a - 0.025J_y - 0.01J_s \tag{2.1}$$

提供尺度已知的基本偏好。actor 学习候选残差 $r_\theta(o,\tau)$，得到

$$z_\theta(o,\tau) = \bar{q}_{\text{ana}}(o,\tau) + 3\tanh r_\theta(o,\tau), \quad z_\theta = -10^9 \text{ if } m(o,\tau) = 0. \tag{2.2}$$

学习动作只有在相对解析动作的残差优势不少于 0.10 时执行；否则回退解析选择。该门不是事后 挑选，而是在 V5/V6 合同中冻结。

2.3 Asymmetric PPO 与 PCT

PPO 使用裁剪代理目标[1]。actor 只编码 o_t，critic 额外编码 32 维特权 p_t，与 Asymmetric Actor Critic 的训练/执行信息分离思想一致[2]：

$$L_{\text{PPO}} = -L^{\text{clip}} + c_v L_V - c_H \mathcal{H}, \qquad V_\phi = V_\phi(o_t, p_t). \tag{2.3}$$

V5 的 fresh 结果表明，仅让 critic 读取特权状态仍不足以达到 8% 实效门。V6 因此只增加一个 训练因素：在部分遮挡与窄走廊困难族中，根据危险侧、硬掩码和候选速度生成反事实排序目标 $a_t^\star(p_t, m_t)$，并在每次 PPO 更新后进行一次辅助更新：

$$L_{\text{V6}} = L_{\text{PPO}} + lambda_{\text{PCT}}\,\text{CE}\big(\pi_\theta(\cdot \mid o_t, m_t), a_t^\star(p_t, m_t)\big), \quad \lambda_{\text{PCT}} = 0.35. \tag{2.4}$$

这与“先用特权教师、后部署纯传感器学生”的一般思想相关[3]，区别在于本研究 不训练独立全状态驾驶策略，而是在同一个 actor 中蒸馏候选排序，并同时保留 PPO 回报学习。

2.4 硬安全屏蔽

安全不是碰撞惩罚。对每个候选，verifier 检查其短时轨迹及候选之后的可停车尾段；被拒绝候选 在策略分布中概率为零。certified-stop 始终作为失败关闭动作。该角色对应 pre-shielding 的允许 动作集合思想[4, 5]，但本文只有经验完整性验证， 没有时序逻辑或控制屏障函数意义下的形式化证明。

Chapter 3

实验设计与实现

3.1 阶段链与预算

Table 3.1: V5–V6 关键阶段与冻结结论

阶段	唯一目的/因素	新训练步	fresh blocks	结论
V5-01	传感器 actor、特权 critic、硬掩码组件	0	组件审计	通过
V5-02	4 asym、2 symmetric、2 no-prior	1,800,000	验证	通过
V5-03-F1	首次 60 块正式评估	0	60	6.09%，失败
V5-04-D1	纯离线失败归因	0	0	锁定 PCT
V6-01-R1	4 个 V5 初始化身份，各 120k	480,000	160 验证	通过
V6-02-F1	80 块四方法 fresh formal	0	80	8.40%，通过
V6-03/04	传感器 Gazebo 迁移预检	0	3×1	净空门失败

V6 四个训练身份使用 seeds 9501–9504，选择检查点的验证 seeds 为 952100–952259；正式 seeds 953100–953179 在验证门通过前不可访问。每个训练身份在四个交互族与四种方法上采用 Latin 分配，每个“身份×场景族×方法”恰好 5 个 episode。失败 episode 以 20 s 受限值计入，不删除 timeout。

3.2 训练过程与组件审计

组件门以全新困难状态检查 PCT 教师：部分遮挡目标完成率 87/100，窄走廊 63/100，接触与掩码 违规均为零；actor 观测键保持不变，actor-only checkpoint 明确标记 `contains_privileged_modules=false`。图 3.1 显示四个身份均获得稳定的特权排序 监督。总新训练预算为 480,000 步，没有追加、重启或从正式结果选模。

验证阶段解析/V5/V6 受限均时为 14.5281/13.3859/12.9828 s，V6 相对解析降低 10.6367%； 4/4 身份均为正，接触与掩码违规为零，因此正式数据访问门通过。

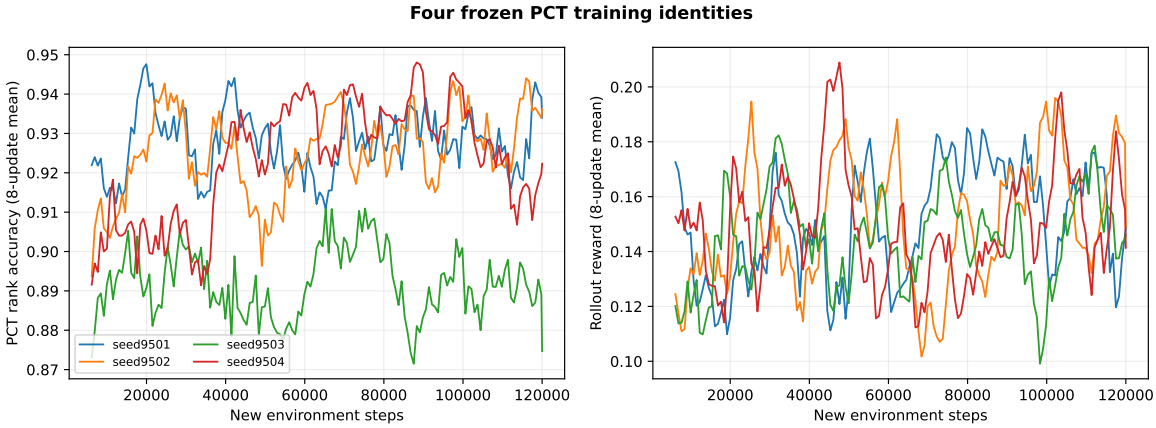


Figure 3.1: 四个 V6 训练身份的 PCT 排序准确率与 rollout reward。

Chapter 4

正式结果

4.1 主效应与任务结果

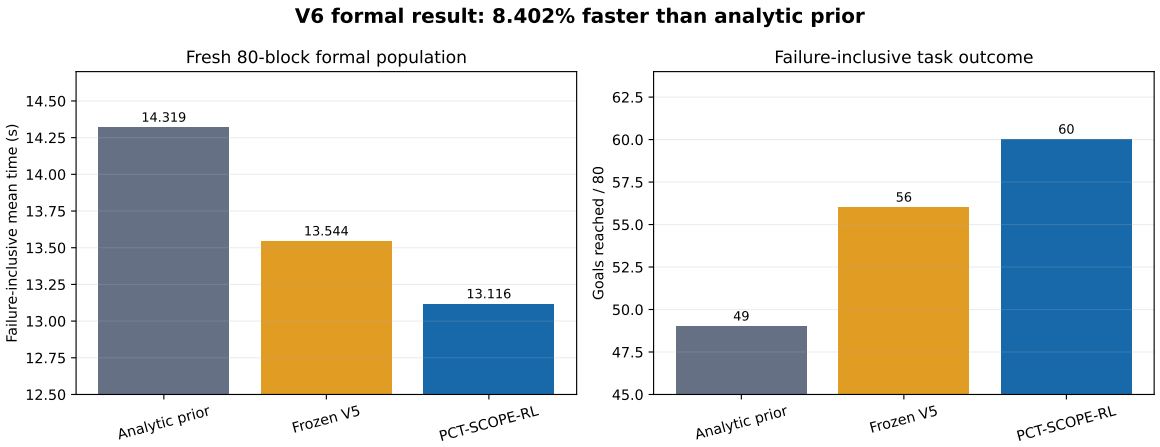


Figure 4.1: 80 个 fresh blocks 的方法均时与目标成功数。

Table 4.1: V6-02-F1 方法级结果

方法	episodes	目标	受限均时/s	最小净空/m	接触/掩码违规
解析先验	80	49	14.3188	0.1113	0/0
冻结 V5	80	56	13.5438	0.1055	0/0
PCT-SCOPE-RL V6	80	60	13.1156	0.1541	0/0
V6 no-history	80	60	13.1156	0.1541	0/0

主估计量为 $1 - \bar{T}_{V6}/\bar{T}_{ana}$，点估计 8.4024%，双侧 97.5% block-bootstrap 区间 [3.4840%,13.7135%]；点估计达到冻结 8% 门、区间下界严格为正、目标数不劣、接触和掩码 违规为零，故正式阳性。相对冻结 V5 的次要降幅为 3.1611%，双侧 95% 区间 [0.4936%,6.5765%]，支持 PCT 单因素带来附加收益。

图 4.2 同时保留 V5 阴性：V5 虽有正区间，但 6.0936% 未达到预注册 8% 实效门。因此不能把 V5 与 V6 合并后重新定义阈值。

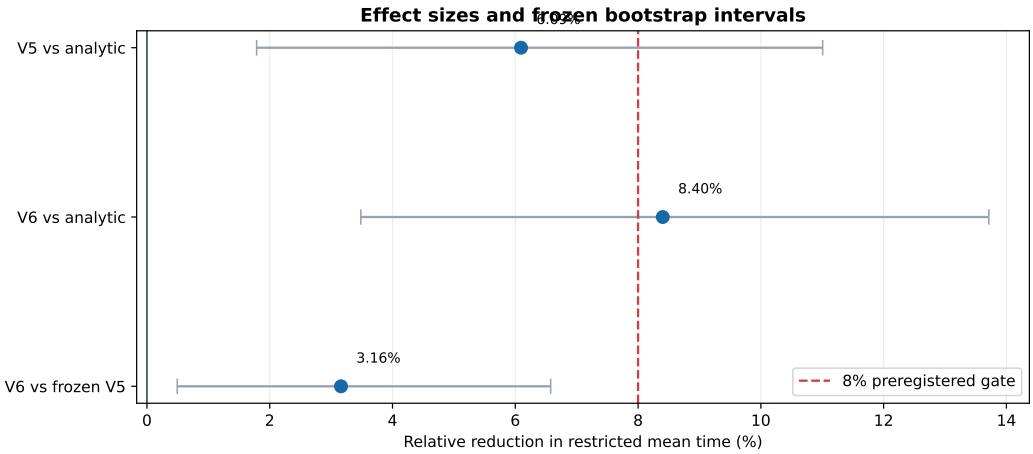


Figure 4.2: V5/V6 效应点估计与冻结 bootstrap 区间。

4.2 场景分解与消融

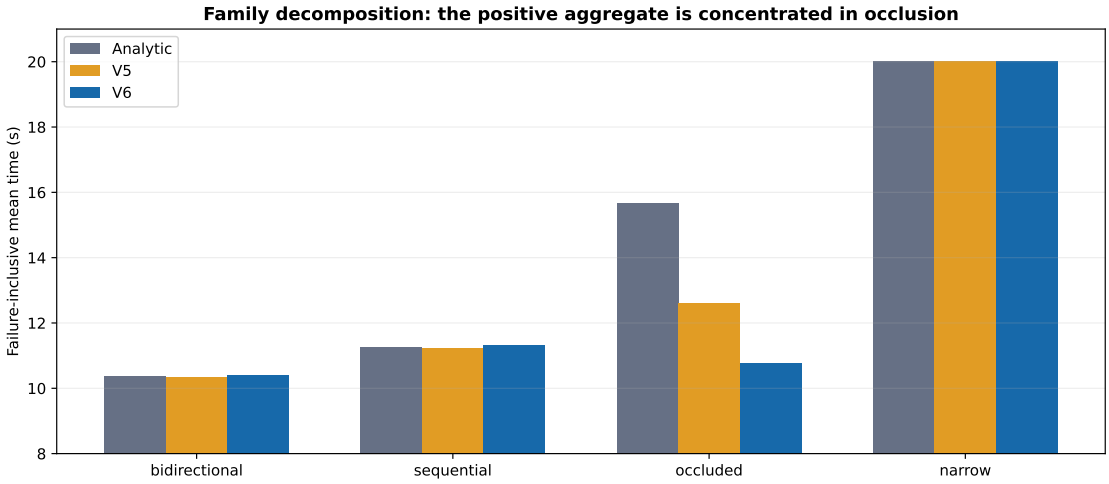


Figure 4.3: 四类交互场景的失效计入均时。

双向 crossing 与顺序双 actor 场景中三种方法接近；主要增益来自部分遮挡：解析/V5/V6 为 15.675/12.600/10.7625 s，V6 完成 20/20，而解析完成 9/20。窄走廊中三种方法均为 0/20，均时 20 s。故本文的有效性声明必须限定为四个合成交互族的总体，其中 PCT 对遮挡族有明显贡献； 不能声称已解决窄走廊让行。

V6 与 no-history 的 80 个正式块完全一致。这意味着 actor 的可部署输入确实包含历史扫描， 但本实验没有识别出 GRU 记忆的独立收益。阳性应归因于 PCT 训练及其产生的候选偏好，不得改写为 “时序端到端网络优于单帧网络” 。

Chapter 5

Gazebo 迁移负结果

5.1 三次预检

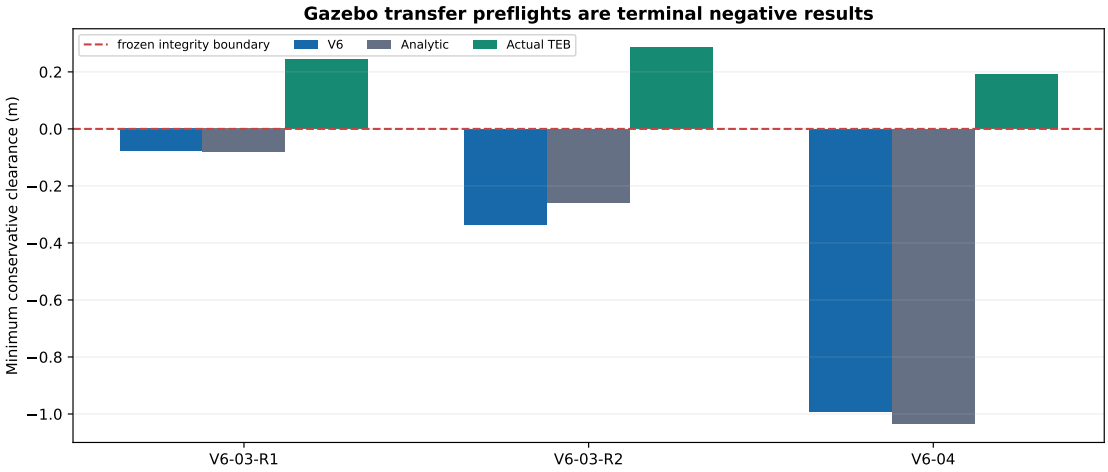


Figure 5.1: 三次 Gazebo 预检的最小保守净空；零线为冻结完整性门。

Table 5.1: Gazebo 预检终局结果（每方法 1 个新鲜 episode）

阶段	方法	目标	受限时间/s	最小保守净空/m
V6-03-R1	V6 / 解析 / Actual TEB	1/1/1	7.60/7.75/7.75	-0.077/-0.081/+0.245
V6-03-R2	V6 / 解析 / Actual TEB	1/1/1	10.40/9.85/7.75	-0.337/-0.258/+0.285
V6-04	V6 / 解析 / Actual TEB	0/1/1	22.00/11.60/7.75	-0.990/-1.034/+0.190

R1 发现扫描表面膨胀 0.12 m 与评价器中心距 1.15 m 不一致。R2 用几何式 $1.15 - 0.36 - 0.46 = 0.33$ m 对齐，而非按性能调参；闭环净空反而恶化，说明静态膨胀不是充分修复。 V6-04 再增加只读 LaserScan+Odometry 的方向可达占用跟踪器，跟踪器门通过，但 V6 超时且净空 进一步为负。三阶段均为零接触，但冻结的保守净空门失败，因此不能以“没有碰撞”为由放行。

5.2 对论文结论的影响

Gazebo 结果没有推翻快速总体内的统计阳性，但限制其外部效度。合理表述是：

> PCT-SCOPE-RL 在冻结的传感器级交互环境中证明了相对解析先验的学习收益；然而，当前在线扫描 屏蔽在反应式 Gazebo actor 下未满足预注册保守净空门，故尚未证明 Gazebo 迁移、Actual TEB 优势或部署安全。

资格 seeds 954201–954206 与正式 seeds 955200–955229 从未执行；不存在挑选更有利 Gazebo episode 的问题。后续研究必须重新设计具有闭环交互一致性的候选条件感知预测/可达占用，而不能 继续放大一个半径常数。

Chapter 6

讨论、贡献与局限

6.1 为什么该工作属于强化学习

策略不是监督分类器：主体以 PPO rollout、GAE、裁剪策略目标、价值回归和熵正则从环境回报训练， 并经历 480,000 个新交互步。PCT 是加入 PPO 的训练期辅助目标，用于解决特权状态不能部署的 信息瓶颈；它没有替代序列回报优化。四个独立训练身份、验证选模和 fresh formal 共同证明结果 不是单次 checkpoint 演示。

6.2 为什么该工作是端到端而非端到端控制

“端到端”限定为从合法传感器到候选轨迹评价：actor 直接编码原始重采样激光与里程计并输出候选 分数，中间不使用人工 actor 真值特征。系统没有端到端输出轮端执行量；Ackermann 生成器、硬 verifier、解析先验、优势门和跟踪器是明确的结构先验。该限定比笼统声称“端到端自动驾驶”更准确， 也更适合安全关键局部导航。

6.3 论文可支持的贡献

- 可运行的 sensor-only candidate-level RL 软件、训练脚本、ROS 节点和 actor-only checkpoint；
- 仿真特权 critic 与候选反事实 PCT 蒸馏的双通道训练机制；
- 解析先验、优势门、硬掩码和 certified-stop 的结构化安全权限分离；
- V5 阴性到 V6 单因素阳性的预注册证据，含 80 块 fresh formal、效应区间与场景消融；
- 将三次 Gazebo 失败原样导出，明确指出传感器屏蔽的 sim-to-sim 迁移缺口。

6.4 禁止扩大的声明

本证据不能支持：一般动态场景有效、任意 TEB 优势、形式化安全、识别/跟踪精度、多 actor/OOD 泛化、实车可用、GRU 历史收益或部署 readiness。Actual TEB 只出现在三个预检单元，且 V6 安全门 失败，不能做性能统计比较。真实机器人从未连接，稳定工作区从未修改。

Chapter 7

复现资源索引

论文资源位于 `artifacts/v6/paper/v6_05_p1_thesis_export/`：

- `v6_02_f1_method_summary.csv`、`v6_effect_summary.csv`：主结果与区间；
- `v6_02_f1_family_summary.csv`、`v6_02_f1_formal_episodes.csv`：场景和逐 episode 数据；
- `v6_gazebo_preflight_summary.csv`：三次迁移预检；
- 六幅 SVG/PDF 图、`v6_05_p1_claims.yaml` 与 primary-source 文献索引；
- `v6_05_p1_evidence_manifest.sha256`：上游证据与实现路径 SHA256；
- `FAM_TEB_V6_PCT_RL_SUPPLEMENT.pdf`：本附录；
- `FAM_TEB_V6_PCT_RL_THESIS_DRAFT.pdf`：在既有 49 页 V4 稿后追加本附录的合并论文稿。

核心实现为 `src/application/v5_e2e_scope_rl/`。V6 主合同、Gazebo 失败和 V6-04 后继均以 独立 release SHA 封存。复现实验时应使用项目虚拟环境运行训练/快速评估，使用 ROS Noetic 系统 Python 运行 Gazebo 节点；两种环境不可混用。

Bibliography

[1] J. Schulman et al., "Proximal Policy Optimization Algorithms," arXiv:1707.06347, 2017. https://arxiv.org/abs/1707.06347

[2] L. Pinto et al., "Asymmetric Actor Critic for Image-Based Robot Learning," RSS, 2018. https://arxiv.org/abs/1710.06542

[3] D. Chen et al., "Learning by Cheating," CoRL, PMLR 100, 2020. https://proceedings.mlr.press/v100/chen20a.html

[4] M. Alshiekh et al., "Safe Reinforcement Learning via Shielding," AAAI, 2018. https://arxiv.org/abs/1708.08611

[5] S. Carr et al., "Safe Reinforcement Learning via Shielding under Partial Observability," arXiv:2204.00755, 2022. https://arxiv.org/abs/2204.00755

[6] C. Rösmann, F. Hoffmann, and T. Bertram, "Integrated Online Trajectory Planning and Optimization in Distinctive Topologies," Robotics and Autonomous Systems, 2017. https://doi.org/10.1016/j.robot.2016.11.007

[7] P. Long et al., "Towards Optimally Decentralized Multi-Robot Collision Avoidance via Deep Reinforcement Learning," arXiv:1709.10082, 2017. https://arxiv.org/abs/1709.10082